

南開大學
Nankai University

自然语言处理课程
实验一报告

文本分类实现

姓名：薛健

学号：2411641

专业：物联网工程

日期：10 月 9 日

目录

一、 实验目的 **2**

二、 实验设置 **2**

2.1 数据集 2
2.2 数据划分 2
2.3 评价指标 2
2.4 实验环境 3

三、 实验方法 **3**

3.1 词袋模型（Task 1） 3
3.2 词向量模型（Task 2） 3
3.3 BERT 微调（Task 3） 3

四、 实验结果 **4**

4.1 BERT 训练过程 4
4.2 六种方案测试集性能 4

五、 分析与讨论 **5**

六、 结论 **6**

一、实验目的

本实验以 NYT 新闻分类任务为载体，系统实现并比较六种方案：二值词袋、词频词袋、预训练 GloVe 平均词向量、在 AG News 语料上训练的 Word2Vec、在 NYT 训练集上训练的 Word2Vec，以及微调 BERT 预训练模型。所有方案统一使用 Accuracy 与 Macro-F1 评价，以理解不同文本表示方法的基本思想、掌握文本分类的标准实验流程，并比较不同方法在性能上的差异。

二、实验设置

2.1 数据集

实验使用两个数据集。NYT 数据集包含 text 与 label 两列，共 11,519 条新闻，类别为 sports、politics、business 三类，分布不均衡（sports 约占 75%），作为文本分类的主数据集；AG News 数据集包含 90,000 条新闻文本（仅 text 列），本实验中仅用于训练 Word2Vec 词向量。

2.2 数据划分

首先对 NYT 数据按新闻文本去重（去重后共 11,447 条），随后按类别分层抽样划分数据集：80% 作为训练集，10% 作为验证集，10% 作为测试集，随机种子固定为 42。除特别说明外，所有实验共用同一数据划分以保证各方法间的可比性，最终统一在测试集上评价。各集样本数与类别分布如表 1 所示。

类别	训练集	验证集	测试集	合计
sports	6877	860	860	8597
politics	1146	144	143	1433
business	1134	141	142	1417
合计	9157	1145	1145	11447

表 1 数据集划分与类别分布（去重后 11,447 条）

2.3 评价指标

Accuracy 为分类正确的样本数占全部测试样本数的比例；Macro-F1 为分别计算每个类别的 F1 值后对所有类别取平均，在类别分布不均衡的情况下更能全面反映模型在不同类别上的分类能力。二者均用于全部方案的最终评价。

2.4 实验环境

实验环境如表 2 所示，BERT 训练与推理使用 GPU 加速。

软件	版本 / 配置
Python	3.12
PyTorch	2.6.0（CUDA）
Transformers	4.57.1
Gensim	4.4.0
scikit-learn	1.7.2

表 2 实验环境

三、实验方法

3.1 词袋模型（Task 1）

文本分词采用小写化后按正则表达式 [a-z]+(?:'[a-z]+)? 提取英文单词（含 don't 一类缩写），词表仅由训练集文本构建，验证集与测试集只做映射，避免数据泄漏。

二值词袋记录词是否在文档中出现：词表中第 i 个词出现记为 1，否则记为 0，不统计出现次数；词频词袋则记录每个词在当前文档中的出现次数。二者均将文档表示为词表大小的向量。分类器统一使用逻辑回归，正则化参数 C 在 {0.1, 1.0, 10.0} 中按验证集 Macro-F1 选取（solver=lbfgs，max_iter=3000），再以选定的 C 在测试集上评价。

3.2 词向量模型（Task 2）

本部分统一使用 100 维词向量，文档向量取文档内全部有效词次对应向量的平均值，重复出现的词重复参与平均。未包含在对应词向量词表中的词在平均时跳过，若整篇文档均未命中则返回零向量。词向量来源共有三种：一是预训练 GloVe 100 维词向量（glove.6B）；二是在 AG News 的 90,000 条新闻文本上自行训练 Word2Vec；三是仅在 NYT 训练集文本上训练 Word2Vec。两组 Word2Vec 均采用 Skip-gram，window=5、min_count=2、negative=5、sample=1e-3、workers=1，训练 10 轮，随机种子为 42。训练时，每篇新闻的分词结果作为一个词序列。得到文档向量后固定词向量，使用逻辑回归分类，调参方式与 3.1 节一致。

3.3 BERT 微调（Task 3）

使用 google-bert/bert-base-uncased 预训练模型，通过序列分类头完成三分类，并对 BERT 主体和分类头进行全参数微调。Tokenization 设置 max_length=64，该长度包含特殊标记；长文本截断，短文本补齐。按作业要求训练 3 轮，批大小为 16，学习率为 2e-5，

weight decay 为 0.01，warmup 比例为 0.1，随机种子为 42，训练时使用 GPU 混合精度。每轮在验证集上评估，训练结束后恢复三个检查点中验证集 Macro-F1 最高的检查点（第 3 轮 checkpoint-1719），再在测试集上评价。

四、实验结果

4.1 BERT 训练过程

训练日志每 50 步记录一次训练损失。第 50 步记录的损失为 1.1434，第 250 步下降至 0.0952，后期整体处于较低水平并有波动，第 1700 步为 0.0186（图 1）。验证集指标随训练轮数逐轮提升：第 1 轮 Accuracy 为 97.21%、Macro-F1 为 93.71%；第 2 轮分别为 97.64%、94.51%；第 3 轮分别为 97.82%、94.98%。因此，按预设的 Macro-F1 规则选择第 3 轮末的检查点。三轮验证损失分别约为 0.0972、0.0851、0.0938，第三轮有所回升，说明训练损失下降并不意味着所有验证指标都持续改善。

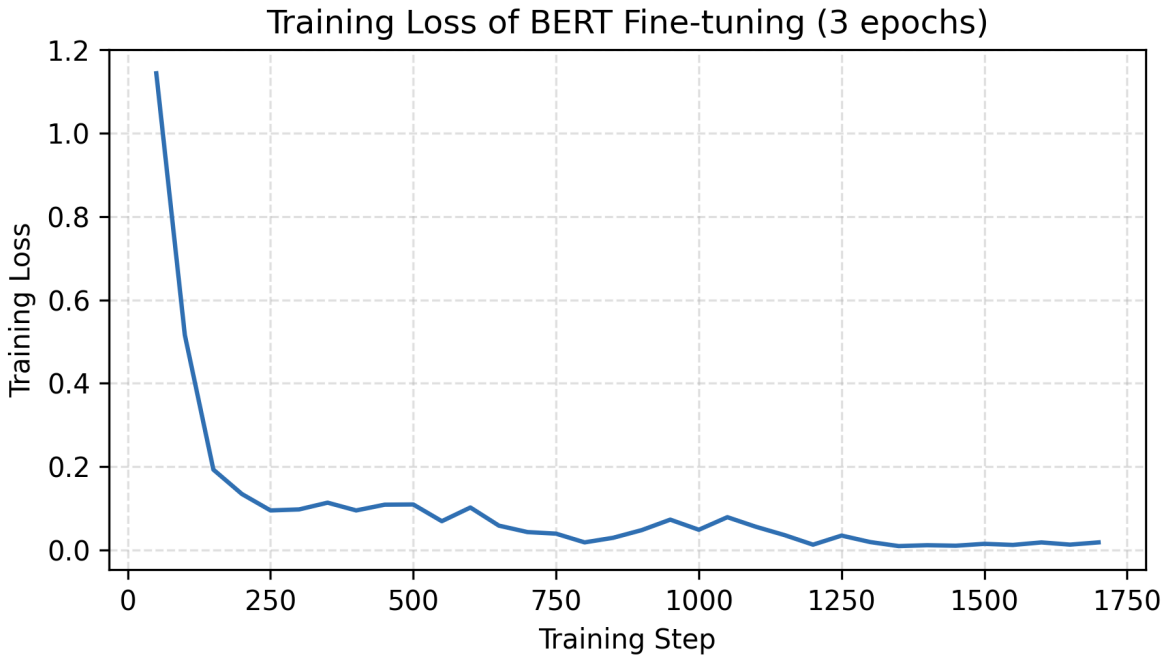


图 1 BERT 微调训练损失曲线（3 轮，共 1719 步）

4.2 六种方案测试集性能

六种方案在验证集上选择的超参数与测试集性能汇总于表 3，测试集 Accuracy 与 Macro-F1 的对比见图 2。二值词袋配合逻辑回归在两项测试指标上均取得最高值（Accuracy 98.52%、Macro-F1 96.81%），GloVe 次之（98.25%、96.01%）。NYT Word2Vec 与词频词袋的测试准确率均为 98.17%，但 Macro-F1 分别为 95.75% 和 95.67%。BERT 的测

试 Accuracy 为 97.12%、Macro-F1 为 94.01%，在本次六个方案中最低。验证集 Macro-F1 最高的是词频词袋（97.95%），BERT 的 94.98% 仅是自身三个训练检查点中的最高值。

方法	best_C	验证集 Macro-F1	测试集 Accuracy	测试集 Macro-F1
Binary BoW + LR	0.1	96.40%	98.52%	96.81%
Word Frequency + LR	0.1	97.95%	98.17%	95.67%
GloVe + LR	10.0	97.16%	98.25%	96.01%
AG Word2Vec + LR	10.0	95.48%	97.47%	94.13%
NYT Word2Vec + LR	10.0	96.50%	98.17%	95.75%
BERT（checkpoint-1719）	—	94.98%	97.12%	94.01%

表 3　六种方案的超参数与测试集性能

注：BERT 的 best_C 不适用，以 “—” 表示。五种逻辑回归方案的参数与指标来自保存的结果 CSV；BERT 验证指标来自 checkpoint-1719 的训练日志，测试指标来自 BERT 结果 CSV。

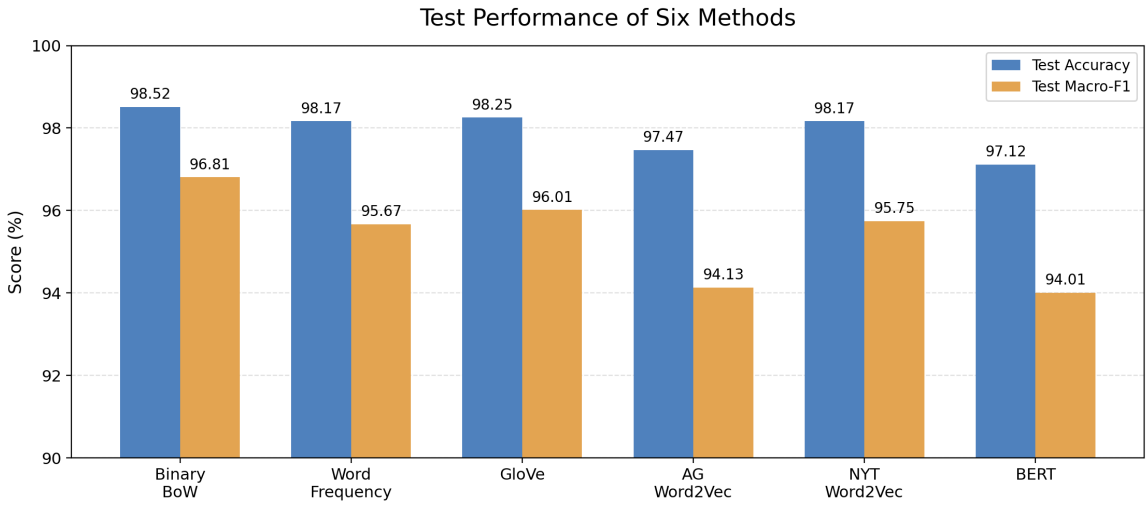


图 2　六种方案测试集 Accuracy 与 Macro-F1 对比

五、分析与讨论

在本次固定数据划分和参数设置下，二值词袋取得了最高的测试 Accuracy 和 Macro-F1。一个可能的原因是新闻类别与主题词的出现具有较强关联，二值词袋能够保留这些词的存在信息。由于 sports 占比较高，仅看 Accuracy 容易掩盖少数类别的误差，因此需要同时考察 Macro-F1 和各类别指标。

三种平均词向量方案中，GloVe 的测试表现最好（Accuracy 98.25%、Macro-F1 96.01%），其次是 NYT Word2Vec（98.17%、95.75%），最后是 AG Word2Vec（97.47%、94.13%）。NYT Word2Vec 的 Macro-F1 比 AG Word2Vec 高约 1.62 个百分点，两组 Word2Vec 使用相同的训练超参数，但语料来源、规模、文本长度和词汇覆盖情况并不相同，因此语域匹配可以作为一种可能解释，但不能将差异完全归因于这一因素。

BERT 在自身三轮训练中，以第 3 轮的验证集 Macro-F1 94.98% 为最高值，其测试结果（97.12% / 94.01%）也未超过词袋基线。与使用整篇新闻构建词袋或平均词向量的方案相比，BERT 的输入限制为 64 个 token，截断可能损失后续内容；训练样本规模、类别分布和训练参数也可能影响表现。

对本次实验而言，在数据量较小、类别可辨识度较高的新闻分类场景中，词袋特征配合线性分类器具备很强的竞争力；预训练语言模型的能力需要通过增加训练数据、提高输入长度或调整训练参数来进行提升，对于是否能改善 BERT 的表现的结论还需要进一步实验验证。

六、结论

本实验实现并比较了六种新闻分类方案，使用相同的数据划分，以 Accuracy 和 Macro-F1 评价最终测试表现。二值词袋配合逻辑回归最好，测试 Accuracy 为 98.52%，Macro-F1 为 96.81%。三种平均词向量方案的测试表现依次为 GloVe、NYT Word2Vec 和 AG Word2Vec。BERT 完成了 3 轮全参数微调，按验证集 Macro-F1 选择第 3 轮检查点，最终测试 Accuracy 为 97.12%，Macro-F1 为 94.01%。本实验完成了六种方案，并在相同的 NYT 测试集上进行比较，观察到了不同文本表示方法在当前设置下的性能差异。